


Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
GRADUATION THESIS

Разработка мультимодального метода одометрии для мобильных роботов по данным
камеры и лидара

Обучающийся / Student Дюжев Владислав Дмитриевич
Факультет/институт/кластер/ Faculty/Institute/Cluster факультет систем управления и
робототехники
Группа/Group R34353
Направление подготовки/ Subject area 15.03.06 Мехатроника и робототехника
Образовательная программа / Educational program Робототехника и искусственный
интеллект 2021
Язык реализации ОП / Language of the educational program Русский
Квалификация/ Degree level Бакалавр
Руководитель ВКР/ Thesis supervisor Ведяков Алексей Алексеевич, доцент, кандидат
технических наук, Университет ИТМО, факультет систем управления и робототехники,
доцент (квалификационная категория "ординарный доцент")

Обучающийся/Student


Документ подписан	
Дюжев Владислав Дмитриевич	
13.05.2025	

(эл. подпись/ signature)

Дюжев
Владислав
Дмитриевич

(Фамилия И.О./ name
and surname)

Руководитель ВКР/
Thesis supervisor

Документ подписан	
Ведяков Алексей Алексеевич	
13.05.2025	

(эл. подпись/ signature)

Ведяков
Алексей
Алексеевич

(Фамилия И.О./ name
and surname)

**Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University**

**ЗАДАНИЕ НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ РАБОТУ /
OBJECTIVES FOR A GRADUATION THESIS**

Обучающийся / Student Дюжев Владислав Дмитриевич
Факультет/институт/кластер/ Faculty/Institute/Cluster факультет систем управления и робототехники
Группа/Group R34353
Направление подготовки/ Subject area 15.03.06 Мехатроника и робототехника
Образовательная программа / Educational program Робототехника и искусственный интеллект 2021
Язык реализации ОП / Language of the educational program Русский
Квалификация/ Degree level Бакалавр
Тема ВКР/ Thesis topic Разработка мультимодального метода одометрии для мобильных роботов по данным камеры и лидара
Руководитель ВКР/ Thesis supervisor Ведяков Алексей Алексеевич, доцент, кандидат технических наук, Университет ИТМО, факультет систем управления и робототехники, доцент (квалификационная категория "ординарный доцент")

Характеристика темы ВКР / Description of thesis subject (topic)

Тема в области фундаментальных исследований / Subject of fundamental research: нет / not

Тема в области прикладных исследований / Subject of applied research: да / yes

Основные вопросы, подлежащие разработке / Key issues to be analyzed

Рассматривается задача оценки перемещения мобильного робота, конструкция которого предполагает наличие одновременно стерео-камеры и лидара. Требуется исследовать и совместить методы визуальной и лидарной одометрии для повышения устойчивости определения траектории движения по сравнению с использованием только одного из датчиков. Базовых метод метод совмещения данных должен быть выбран по результатам предварительного анализа. Разработанный прототип необходимо протестировать на открытых наборах данных, в частности на The KITTI Vision Benchmark Suite (Visual Odometry).

Цель работы — разработать и исследовать мультимодальный алгоритм одометрии, комбинирующий информацию от стерео-камеры и лидара, и определить рекомендации по применению такого подхода в робототехнике.

Задачи:

1. Проведение аналитического обзора в области методов одометрии на основе данных камеры и лидара, включая способы их комбинирования.

2. Выбор подходящего метода интеграции визуальных и лидарных данных.
3. Реализация прототипа мультимодального алгоритма одометрии, обеспечивающего оценку движения мобильного робота.
4. Проведение серии экспериментов на открытых датасетах, сравнительного анализа полученных результатов с отдельными схемами (только камера / только лидар), а также другими представителями мультимодальных методов.
5. Формирование методических рекомендаций по использованию и настройке полученного решения, включая потенциальные сценарии и ограничения.

Требования к разрабатываемому решению:

1. Разрабатываемая система рассчитана на использование данных стерео RGB или монохромной камеры с разрешением 1382 x 512 и частотой не менее 10 Гц, а также 3D лидара с 64 вертикальными каналами, работающем на частоте не менее 10 Гц.
2. Подразумеваются доступными данные калибровки, включающие в себя параметры камеры, а также взаимное расположение камеры и лидара.
3. Средняя частота обработки данных должна составлять не менее 8 Гц.
4. По результатам серии экспериментов средняя относительная ошибка оценки пройденного пути не должна превышать 2%, а относительная ошибка ориентации – 0.006 град/м на The KITTI Vision Benchmark Suite (Visual Odometry).
5. Аппаратные ограничения: объём доступной оперативной памяти не менее 8 ГБ, CPU с частотой 2 ГГц и выше, 8 ГБ видеопамати.
6. Наличие описания процесса настройки алгоритма, шагов калибровки и воспроизведения экспериментов.

Исходные данные:

1. Lee D. et al. LiDAR odometry survey: recent advancements and remaining challenges //Intelligent Service Robotics. – 2024. – Т. 17. – No. 2. – С. 95-118.
2. He M. et al. A review of monocular visual odometry //The Visual Computer. – 2020. – Т. 36. – No. 5. – С. 1053-1065.
3. Vizzo I. et al. Kiss-icp: In defense of point-to-point icp—simple, accurate, and robust registration if done the right way //IEEE Robotics and Automation Letters. – 2023. – Т. 8. – No. 2. – С. 1029-1036.
4. Koide K. et al. Glim: 3d range-inertial localization and mapping with gpu-accelerated scan matching factors //Robotics and Autonomous Systems. – 2024. – Т. 179. – С. 104750.
5. Yuan Z. et al. SDV-LOAM: semi-direct visual–LiDAR Odometry and mapping //IEEE Transactions on Pattern Analysis and Machine Intelligence. – 2023. – Т. 45. – No. 9. – С. 11203-11220.

По результатам разработки должен быть представлен программный прототип мультимодального метода одометрии, включающий интегрированную схему работы с данными лидара и стерео камеры, а также отчёт с описанием архитектуры решения, сравнительными экспериментами и методическими рекомендациями по использованию.

Дата выдачи задания / Assignment issued on: 18.02.2025


Срок представления готовой ВКР / Deadline for final edition of the thesis 20.05.2025

СОГЛАСОВАНО / AGREED:

Руководитель ВКР/

Документ	
----------	--


Thesis supervisor

подписан	
Ведяков Алексей Алексеевич	
16.04.2025	

(эл. подпись)

Ведяков
Алексей
Алексеевич


Задание принял к
исполнению/ Objectives
assumed BY

Документ подписан	
Дюжев Владислав Дмитриевич	
16.04.2025	

(эл. подпись)

Дюжев
Владислав
Дмитриевич

Руководитель ОП/ Head
of educational program

Документ подписан	
Бобцов Алексей Алексеевич	
06.05.2025	

(эл. подпись)

Бобцов Алексей
Алексеевич

**Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University**

**АННОТАЦИЯ
ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ
SUMMARY OF A GRADUATION THESIS**

Обучающийся / Student Дюжев Владислав Дмитриевич
Факультет/институт/кластер/ Faculty/Institute/Cluster факультет систем управления и робототехники
Группа/Group R34353
Направление подготовки/ Subject area 15.03.06 Мехатроника и робототехника
Образовательная программа / Educational program Робототехника и искусственный интеллект 2021
Язык реализации ОП / Language of the educational program Русский
Квалификация/ Degree level Бакалавр
Тема ВКР/ Thesis topic Разработка мультимодального метода одометрии для мобильных роботов по данным камеры и лидара
Руководитель ВКР/ Thesis supervisor Ведяков Алексей Алексеевич, доцент, кандидат технических наук, Университет ИТМО, факультет систем управления и робототехники, доцент (квалификационная категория "ординарный доцент")

**ХАРАКТЕРИСТИКА ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ
DESCRIPTION OF THE GRADUATION THESIS**

Цель исследования / Research goal

Разработать и исследовать мультимодальный алгоритм одометрии с использованием данных стерео-камеры и лидара, выделить рекомендации по применению такого подхода в задачах автономной навигации мобильных роботов.

Задачи, решаемые в ВКР / Research tasks


1. Аналитический обзор методов лидарной и визуальной одометрии. 2. Выбор базового мультимодального подхода и разработка его модификации. 3. Проведение сравнительных испытаний метода с базовой версией, а также другими современными методами лидарной и визуальной одометрии. 4. Формирование рекомендаций по использованию разработанного метода. 5. Анализ возможных улучшений и направлений будущих исследований.

Краткая характеристика полученных результатов / Short summary of results/findings

Проведен аналитический обзор существующих методов лидарной и визуальной одометрии. Выбран метод DVLO в качестве базового для дальнейшей модификации. Разработан метод Stereo-DVLO на языке Python с использованием открытых библиотек для глубокого обучения, расширяющий базовый. Проведено обучение и валидация метода, демонстрирующая преимущество разработанного метода. Средняя частота обработки потока данных составляет 10.2 Гц при использовании до 6 Гб видеопамати. Обеспечиваются относительные ошибки оценки расстояния и ориентации на уровне 0.91%

и 0.46 град/100м соответственно. Полученные характеристики удовлетворяют требованиям, установленным в техническом задании — частота работы не менее 8 Гц, количество доступной видеопамяти не менее 8 Гб, относительные ошибки расстояния и ориентации менее 2% и 0.6 град/100м. Сформулированы методические рекомендации по использованию метода Stereo-DVLO. Предложены направления проведения дальнейших исследований.

Обучающийся/Student


Документ подписан	
Дюжев Владислав Дмитриевич	
13.05.2025	

(эл. подпись/ signature)

Дюжев
Владислав
Дмитриевич

(Фамилия И.О./ name
and surname)

Руководитель ВКР/
Thesis supervisor

Документ подписан	
Ведяков Алексей Алексеевич	
13.05.2025	

(эл. подпись/ signature)

Ведяков
Алексей
Алексеевич

(Фамилия И.О./ name
and surname)

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	9
1 Аналитический обзор	11
1.1. Существующие подходы визуальной одометрии и SLAM	11
1.1.1. Методы на основе ключевых точек	13
1.1.2. Прямые методы	14
1.1.3. Нейросетевые методы	15
1.2. Технологии одометрии и SLAM на базе лидаров	15
1.2.1. Прямые методы	17
1.2.2. Методы на основе ключевых точек	18
1.2.3. Нейросетевые методы	19
1.3. Мультимодальные системы: совмещение визуальных и лидар- ных данных	19
1.3.1. Методы со слабой связью	19
1.3.2. Методы с сильной связью	20
2 Описание метода	21
2.1. Выбор базового метода	21
2.2. Принцип работы	22
2.2.1. Иерархическая экстракция признаков	22
2.2.2. Локальное объединение признаков	22
2.2.3. Глобальное объединение признаков	23
2.2.4. Итеративная оценка положения	24
2.2.5. Функция потерь	26
2.3. Стереомодификация	26
3 Экспериментальная проверка	28
3.1. Набор данных	28
3.1.1. Предоставляемые данные	28
3.1.2. Структура и разбиение последовательностей	28
3.1.3. Предобработка калибровочных данных	29
3.1.4. Метрики оценки	29
3.2. Методика экспериментов	29

3.3. Анализ результатов	30
4 Методические рекомендации	35
4.1. Рекомендации по использованию	35
4.2. Потенциальные улучшения	35
4.2.1. Учёт временного контекста посредством трансформера	36
4.2.2. Использование оценки глубины	36
ЗАКЛЮЧЕНИЕ	37
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	38
ПРИЛОЖЕНИЕ А ИЗОБРАЖЕНИЕ КАК НАБОР ТОЧЕК	44

ВВЕДЕНИЕ

В последние годы рынок робототехники и автономных систем стремительно развивается. В частности, растет спрос на мобильных роботов, которые всё активнее внедряются в различные отрасли, такие как логистика, сельское хозяйство, городской транспорт и сфера услуг. При этом важнейшим вызовом для подобных систем остаётся задача локализации – определения собственного положения и ориентации робота в пространстве. Неточности при локализации могут привести к неэффективной или нештатной работе, что в конечном итоге может стать причиной аварий и сбоев.

Исторически для решения задачи локализации и построения карты (SLAM – Simultaneous Localization and Mapping) используются такие сенсоры, как камеры, лидары, IMU (инерционные датчики) и колёсные одометры. Каждая из модальностей имеет ряд преимуществ и недостатков. Например, камеры позволяют обрабатывать насыщенную визуальную информацию, что даёт возможность использовать особенности (признаки текстуры, цветные объекты и т. д.) и проводить оценку положения на основе сравнительно простого аппаратного обеспечения. Однако в условиях плохого освещения или отсутствия достаточного разнообразия признаков эффективность визуальных методов сильно падает. Лидары, напротив, обеспечивают надёжное измерение расстояния до объектов в широком диапазоне и с высокой точностью, но не несут в себе цветовой или текстурной информации. Их точность также может падать при определенных погодных условиях (туман, дождь, снегопад).

Именно поэтому возникает необходимость использования мультимодального подхода: в частности, использование одновременно данных камеры и лидара (Visual-LiDAR Odometry) обещает более высокую точность и стабильность в самых разных сценариях. Подобные мультимодальные системы уже исследуются и применяются в автомобильной отрасли (автономные машины), роботах-курьерах и сервисных платформах, складской логистике и других сферах.

В рамках данной выпускной квалификационной работы ставится цель разработать метод одометрии, совмещающий данные лидара и камеры, а также исследовать его работоспособность. Актуальность темы работы обусловлена возросшими требованиями к автономным системам, которым необходимы более точные и отказоустойчивые методы оценки собственного движе-

ния. Совмещение различных типов сенсорных данных позволяет более полно использовать доступную информацию об окружающей среде и снизить риск ошибок в локализации. Научно-практическая значимость работы состоит в том, что выводы, сделанные в ходе анализа и экспериментов, могут быть использованы при построении мультимодальных SLAM-систем в различных робототехнических приложениях.

1 Аналитический обзор

1.1. Существующие подходы визуальной одометрии и SLAM

Задача визуальной одометрии (ВО) [1] состоит [2] [3] в оценке траектории движения камеры $\mathcal{T}_{VO}$ путём анализа последовательности изображений $\{I_k\}_{0:K}$. SLAM (англ. Simultaneous navigation and mapping) предполагает построение глобальной карты, а также проведение дополнительных оптимизаций траектории. Сама траектория представляет из себя набор положений камеры в обозначенной глобальной системе координат:

$$\mathcal{T}_{VO} = \{C_k\}_{0:K},$$

где C_k — положение камеры в момент k . Чаще всего глобальная система координат выбирается согласно первому положению камеры в последовательности.

В качестве подзадачи рассматривается оценка пространственной трансформации между последующими положениями камеры T_k^{k-1} на основе кадров I_{k-1} и I_k .

$$T_k^{k-1} = \begin{bmatrix} R_k^{k-1} & t_k^{k-1} \\ 0 & 1 \end{bmatrix},$$

где $R_k^{k-1} \in \mathbb{R}^{3 \times 3}$, $t_k^{k-1} \in \mathbb{R}^3$ — матрица поворота и вектор смещения между кадрами соответственно. Можем выразить положения камеры следующим образом:

$$C_k = \prod_{i=1}^k T_i^{i-1}.$$

Положим, что соседние кадры I_0 и I_1 содержат наборы соответствующих друг другу точек в однородной системе координат $\{p_i^1\} \in \mathbb{R}^3$ и $\{p_i^0\} \in \mathbb{R}^3$. Тогда, выполнено эпполярное ограничение с нормализацией [4], представленное в уравнении (1.1):

$$p_i^{1\top} K_c^{-\top} E K_c^{-1} p_i^0 = 0, \quad (1.1)$$

где $K_c \in \mathbb{R}^{3 \times 3}$ — матрица калибровки камеры (англ. camera matrix), $E \in \mathbb{R}^{3 \times 3}$

— эссенциальная матрица (англ. essential matrix).

Существуют методы, позволяющие оценить значение эссенциальной матрицы, на основе наборов точек $\{p_i^1\}$ и $\{p_i^0\}$. Наиболее популярными являются восьмиточечный [5] и пятиточечный [6] алгоритмы. Часто для улучшения качества оценки применяется RANSAC [7].

На основе полученной оценки эссенциальной матрицы возможно восстановить взаимную ориентацию камер, а также направление смещения. Важно заметить, что в постановке задачи монокулярной одометрии невозможно оценить метрическое значение вектора смещения без дополнительной информации. Кроме того, ориентация восстанавливается согласно уравнению (1.2) не единственным способом:

$$R_1^0 = U W V^\top, t_1^0 = \pm u_3 \vee R_1^0 = U W^\top V^\top, t_1^0 = \pm u_3, \quad (1.2)$$

где U, V — матрицы правых и левых сингулярных векторов в разложении E , $W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$, u_3 — третий столбец матрицы U . Т.к. значение длины вектора t_1^0 невозможно восстановить на данном этапе, обычно оно принимается равным 1.

Так как полученная оценка неоднозначна, требуется дополнительная валидация. Наиболее распространенным подходом является триангуляция [8] с целью получения оценок пространственных координат соответствующих точек. Выбирается конфигурация, обеспечивающая валидное положение точек относительно камеры, а именно — точки должны находиться перед камерами (не иметь отрицательную глубину). Полученная конфигурация положений камеры и точек в пространстве позволят построить базовую 3D карту.

Для сохранения единого масштаба, начиная с обработки 3 кадра применяются методы 2D-3D сопоставления [9] при оценке последующих трансформаций (после первой итерации и триангуляции получены 3D координаты сопоставляемых точек). Наиболее широко используемыми являются методы EPnP [10], UPnP [11] и OPnP [12].

Выше указанные методы склонны к быстрому накоплению ошибок, что приводит к искажению масштаба и структуры. Возможным решением является применение алгоритма групповой корректировки (Bundle Adjustment) [13],

решающего оптимизационную задачу минимизации ошибки перепроецирования путем восстановления одновременно положений камер и точек. Ранее оцененная структура используется в качестве начальных условий. Такой подход позволяет значительно повысить устойчивость и качество оценок, однако требует значительных вычислительных ресурсов. В связи с этим, групповая корректировка обычно применяется с частотой меньшей, чем предыдущие шаги.

Рассмотренный выше подход является общим для большинства методов визуальной одометрии. При дальнейшем описании методов сделан акцент на ключевые отличия или особенности, заключающиеся в деталях реализации таких как способы детекции и сопоставления статичных точек, восстановления масштаба с использованием семантической информации, модификации оптимизационных задач.

1.1.1. Методы на основе ключевых точек

Большую часть методов визуальной одометрии на данный момент составляют методы на основе ключевых точек. Идея состоит в детекции устойчивых точек, обладающих важной семантической или геометрической информацией и дальнейшее сопоставление их между кадрами. В остальном зачастую процесс следует общей методологии.

Семейство методов ORB-SLAM [14] [15] [16] — одни из наиболее известных и эффективных методов визуальной одометрии и построения карт. Их подход к одометрии включает в себя три основных модуля:

- 1) трекинг,
- 2) создание карты,
- 3) замыкание цикла.

Трекинг осуществляется путем выделения бинарных ORB-дескрипторов [17] на изображении и применении процедуры ассоциации данных на основе расстояния Хэмминга. Для задачи замыкания цикла производится сопоставление наблюдаемых ключевых точек с сохраненными в карте. С помощью метода Bag of Words [18] проверяются гипотезы о совпадении. При обнаружении совпадения производится глобальная оптимизация на позиционном графе [19] — данная процедура схожа с групповой корректировкой, однако оптимизация

производится только по отношению к положениям камеры, а не камеры и точек.

PLP-SLAM [20] использует помимо визуальных признаков также геометрические в виде линий, которые извлекаются с помощью LSD [21] и преобразуются в LBD-дескрипторы [22]. Таким образом в ассоциации данных участвуют также признаки, обладающие важной геометрической информацией. Кроме того, система становится более устойчива и модули локальной групповой корректировки, а также замыкания цикла работают более эффективно.

1.1.2. Прямые методы

Прямые методы не используют дискретный набор точек-признаков. Вместо этого, их главная идея заключается в оптимизации значения фотометрической ошибки на основе интенсивности точек при их проецировании на изображения. Таким образом прямые методы сводят задачу 2D-3D сопоставления к чисто оптимизационной.

Широко известным прямым методом является DSO [23] (англ. Direct Sparse Odometry). Суть заключается в выборе подмножества точек с сильным градиентом интенсивности. Каждой точке присваивается значение глубины d . Выбирается последовательность ключевых кадров. Общая функция ошибки по всем кадрам в скользящем окне и точкам:

$$\mathcal{E} = \sum_{i \in \mathcal{F}} \sum_{j \in \mathcal{N}(i)} \sum_{p_i \in P_i} w_{i,j}(p_i) \rho \left(I_j(\pi(T_j^i x_i)) - I_i(p_i) \right), \quad (1.3)$$

где $\mathcal{F}$ — множество ключевых кадров в окне оптимизации, $\mathcal{N}(i)$ — множество соседних ключевых кадров к i , P_i — набор разреженных точек в кадре i (по принципу сильного градиента), $w_{i,j}(p_i)$ — весовой коэффициент, $\rho(\cdot)$ — робастная функция потерь (например, Хубера или Коши), $\pi(x)$ — оператор перспективной проекции 3D-точки x в 2D-координаты на изображении. Путем последовательного решения оптимизационной задачи $\min_{d,T}(\mathcal{E})$ для ошибки из уравнения (1.3) восстанавливаются глубины точек и взаимные расположения камеры. Данный подход демонстрирует высокую точность, сопоставимую с методами на основе ключевых точек, однако требует значительных вычислительных ресурсов. Кроме того, в окружениях с отсутствием текстурированных поверхностей прямые являются более устойчивыми. К их слабым сторонам

можно отнести чувствительность к резким изменениям интенсивности.

1.1.3. Нейросетевые методы

В последнее время широкую популярность набирают нейросетевые методы монокулярной визуальной одометрии. Существует множество их разновидностей, предлагающих различные способы интеграции нейросетей в данную задачу. Такие методы как SuperPoint [24] SLAM, Droid SLAM [25] используют нейросетевые дескрипторы для определения целевых точек. В методе SuperVO [26] используется графовая нейронная сеть для построения ассоциаций между детектированными признаками. Некоторые подходы, такие как Dyna-VO [27] используют нейросети в качестве модуля сегментации движущихся объектов, что позволяет избегать формирования признака на них и значительно повысить робастность.

Особый интерес представляют нейросетевые методы, решающие задачу целиком. MagicVO [28] обладает сверточно-рекуррентной архитектурой с механизмами внимания, позволяющей эффективно анализировать визуально-временную информацию. Обучение предполагается проводить напрямую на наборах данных с сопоставлением реального перемещения камеры. Стоит отметить, что итоговый выход модели соответствует реальному масштабу в отличие от большинства рассмотренных выше методов.

1.2. Технологии одометрии и SLAM на базе лидаров

Задача лидарной одометрии [29] состоит в оценке траектории движения лидара $\mathcal{T}_{LO}$ путём анализа последовательности облаков точек $\{P_k\}_{0:K}$, полученных последовательно в моменты времени k :

$$\mathcal{T}_{LO} = \{L_k\}_{0:K},$$

где L_k — положение сенсора в глобальной системе координат в момент k . Чаще всего, аналогично визуальной одометрии, за глобальную систему координат выбирается положение сенсора в момент начала записи траектории.

В качестве основной подзадачи лидарной одометрии выступает оценка пространственной трансформации между соседними положениями сенсора

T_k^{k-1} на основе облаков точек P_{k-1} и P_k и итоговые положения лидара формируются следующим образом:

$$L_k = \prod_{i=1}^k T_i^{i-1}.$$

Наиболее распространённый подход к оценке трансформации между облаками точек P_{k-1} и P_k — это алгоритм Iterative Closest Point (ICP) [30]. Предполагая известными соответствия между точками двух облаков, ICP итеративно минимизирует ошибку расстояния между ними:

$$E(R_k^{k-1}, t) = \sum_{i=1}^N \|p_i^k - (R_k^{k-1} p_i^{k-1} + t)\|^2,$$

где $p_i^k \in P_k$, а $p_i^{k-1} \in P_{k-1}$ — соответствующие точки в соседних облаках.

Путем решения оптимизационной задачи (1.4) вычисляются оценки R_k^{k-1} и t_k^{k-1} .

$$\min_{R_k^{k-1}, t_k^{k-1}} \sum_{i=1}^N \|p_i^k - (R_k^{k-1} p_i^{k-1} + t)\|^2 \quad (1.4)$$

Поиск соответствий — нерешенная задача, в рамках которой ведутся исследования. В связи с этим часто используют приближённые соответствия ближайших соседей (nearest neighbors):

$$p_i^{k-1} = \arg \min_{p \in P_{k-1}} \|p_i^k - p\|$$

Следующим этапом производится фильтрация выбросов, где используются пороговые значения расстояния для отсеивания неверных соответствий согласно уравнению (1.5).

$$\|p_i^k - p_i^{k-1}\| < \tau \quad (1.5)$$

Для решения оптимизационной задачи часто применяется метод сингулярного разложения (SVD). Центроиды двух наборов соответствующих точек определяются следующим образом:

$$\mu_k = \frac{1}{N} \sum_{i=1}^N p_i^k, \quad \mu_{k-1} = \frac{1}{N} \sum_{i=1}^N p_i^{k-1}.$$

Можем записать ковариационную матрицу и ее сингулярное разложение:

$$W = \sum_{i=1}^N (p_i^{k-1} - \mu_{k-1})(p_i^k - \mu_k)^\top, \quad W = U\Sigma V^\top.$$

Решение для трансформации находится согласно уравнению (1.6).

$$R_k^{k-1} = VU^\top, \quad t_k^{k-1} = \mu_k - R_k^{k-1}\mu_{k-1}. \quad (1.6)$$

Однако точность ICP сильно зависит от качества начальной оценки. Кроме того, метод склонен к застреванию в локальных минимумах. Для преодоления этих проблем используются методы извлечения геометрических признаков.

Важно отметить, что, облака точек, полученные вращающимся лидаром, искажаются движением сенсора. Поэтому перед применением ICP необходимо провести компенсацию движения (deskewing) [31], которая обычно основана на модели постоянной скорости:

$$p_{deskewed}(t_i) = T(t_i)^{-1}p_{raw}(t_i),$$

где $T(t_i)$ — трансформация, определённая для момента t_i внутри одного оборота лидара, вычисляемая из предыдущей оценки скорости.

Для уменьшения накопления ошибок, аналогично визуальной одометрии, применяются глобальные методы оптимизации, чаще всего на основе графов, с построением локальной или глобальной карты и замыканием цикла.

1.2.1. Прямые методы

Прямые (англ. direct) методы напрямую вычисляют трансформации между двумя последовательными облаками точек без явного выделения ключевых признаков. Часто применяются усовершенствованные версии ICP, такие как Point-to-Plane ICP [32] и Generalized ICP (GICP) [33], которые учитывают геометрические свойства облаков точек и обеспечивают лучшую устойчивость и сходимость.

Метод Normal Distribution Transform (NDT) [34] решает проблему соответствия точек иначе, используя вероятностный подход для вычисления транс-

формации.

СТ-ICP (Continuous-Time ICP) [35] интерполирует позиции точек внутри облака между начальным и конечным положениями, позволяя эффективно оценивать непрерывную траекторию сенсора, что улучшает точность и устойчивость одометрии в динамичных условиях.

Современный подход KISS-ICP [36] использует стандартную версию ICP с точечным сопоставлением (point-to-point) и адаптивным порогом для валидации соответствия точек, обеспечивая возможность применения с различными типами лидаров и условиями эксплуатации.

1.2.2. Методы на основе ключевых точек

Методы одометрии на основе ключевых точек (англ. feature-based) извлекают характерные точки или признаки из облака точек для последующей оценки перемещения. Использование только выделенных признаков позволяет ускорить вычисления и повысить общую точность, устраняя шумы и выбросы, однако может привести и к потере части значимой информации.

Широко известным подходом является LOAM (LiDAR Odometry and Mapping) [37], который извлекает точки, расположенные на острых гранях и плоских поверхностях, вычисляя локальную гладкость поверхности. Затем производится сопоставление этих точек для оценки движения с помощью ICP. Дальнейшие модификации LOAM, такие как LeGO-LOAM [38], вводят сегментацию облака точек для классификации точек на землю и объекты, что улучшает точность выделения признаков.

Другим значимым представителем является SuMa (Surfel-based Mapping) [39], использующий нормали поверхностей для одометрии. Предлагается сравнивать текущие облака точек с картой, представленной набором локальных элементов плоскостей. SuMa++ [40] расширяет этот подход, вводя семантические метки, полученные при помощи RangeNet++ [41], добавляя ограничения в процедуру ICP, что увеличивает робастность.

Современные SLAM-фреймворки, такие как GLIM [42] и MOLA [43] используют схожие подходы в модулях лидарной одометрии.

1.2.3. Нейросетевые методы

Нейросетевые методы приобретают популярность благодаря возможности автоматического извлечения признаков и адаптации к разнообразным условиям. Эти подходы обычно используют глубокое обучение для выделения и сопоставления признаков между облаками точек.

LO-Net [44] представляет собой нейросетевую архитектуру, предсказывающую нормали и динамические области, а также использующую пространственно-временные ограничения для геометрической согласованности последовательных облаков точек.

Другой представитель — LodoNet [45], где предлагается отбирать пары соответствующих ключевых точек и затем использовать модуль, вдохновленный PointNet [46], для оценки относительного положения.

Подход Чо и др. [47] использует обучение без учителя, оценивая неопределённость точек посредством энкодер-декодер сети. Часть внутренних признаков используется для оценки относительного положения между измеренными облаками другой сетью, обеспечивая робастность и точность в условиях неопределённости.

1.3. Мультимодальные системы: совмещение визуальных и лидарных данных

Задача одометрии на основе слияния данных лидара и монокулярной камеры состоит в оценке траектории движения устройства путём совместного анализа последовательностей изображений и облаков точек. Основная сложность задачи заключается в эффективном объединении двух существенно различных типов данных.

1.3.1. Методы со слабой связью

Методы со слабой связью (англ. Loosely-coupled), такие как V-LOAM [48], сначала независимо получают оценки перемещения на основе каждого сенсора, а затем объединяют их или используют результаты работы одного алгоритма в качестве источника начальных условий или надстройки для другого. В частности, изображения используются для первичной оценки перемещения,

а облака точек лидара используются для уточнения масштаба и коррекции дрейфа с использованием, например, расширенного фильтра Калмана (EKF).

В настоящее время публикуется довольно мало работ посвященных методам со слабой связью, т.к. данные методы зачастую опускают значимую часть взаимосвязей между данными.

1.3.2. Методы с сильной связью

Методы с сильной связью (англ. Tightly-coupled) интегрируют информацию непосредственно на уровне признаков и формируют единую задачу оптимизации. Например, метод LIMO [49] объединяет изображения и облака точек в едином bundle adjustment, минимизируя совместную ошибку перепроецирования.

DVLO (Deep Visual-LiDAR Odometry) [50] использует глубокую нейронную сеть с иерархическим многоуровневым объединением признаков. Для локального совмещения признаков изображения и облаков точек используются псевдоточки, которые формируются путём проекции на изображение. Для глобального объединения используется цилиндрическая проекция облаков точек в псевдоизображения, затем выполняется адаптивная агрегация признаков. На основе глобальных признаков последовательных кадров производится оценка смещения с помощью многослойного перцептрона.

4DRVO-Net (4D Radar-Visual Odometry Network) [51] использует аналогичный DVLO подход иерархической адаптивной агрегации признаков, однако вместо лидарных применяются радарные данные. Дополнительно учитывается информация о скорости объектов, что позволяет фильтровать динамические помехи и повышать устойчивость оценок. Структура сети позволяет эффективно объединять радарные данные с изображениями и минимизировать ошибки оценки траектории за счет итеративного уточнения на разных масштабах и уровнях признаков.

Основное направление развития мультимодальных методов визуально-лидарной одометрии тесно связано с использованием нейросетевых архитектур.

2 Описание метода

2.1. Выбор базового метода

На основе данных проведенного обзора можно сделать вывод о наличии тренда стремительного развития подходов с применением глубокого обучения в задаче одометрии не смотря на превосходство классических методов в точности оценок. В частности, использование глубоких нейронных сетей в задачах объединения данных разных модальностей позволяет получить качественные обобщения, что может быть применено и в смежных областях. Кроме того, неявные обобщения могут быть значительно более эффективными.

Метод DVLO [50] показывает себя как один из наиболее качественных. Его точность превосходит большинство нейросетевых мультимодальных методов, а также часть классических. Заявленные результаты приведены в таблице 2.1, где t_{rel} и r_{rel} — относительная ошибка положения и относительная ошибка ориентации на 100 м соответственно.

Таблица 2.1 — Сравнение подходов одометрии, на данных KITTI Odometry Benchmark [52]

Метод	Модальность	$t_{rel}, \%$	$r_{rel}, ^\circ/100\text{м}$
<i>Нейросетевые методы</i>			
DVLO [50]	LiDAR + камера	0.82	0.41
H-VLO [53]	LiDAR + камера	1.36	0.43
EfficientLO [54]	LiDAR	0.86	0.41
TransLO [55]	LiDAR	0.99	0.50
D3VO [56]	камера	0.88	0.21
DVSO [57]	камера	0.9	0.21
<i>Классические методы</i>			
VLOAM [58]	LiDAR + камера	0.75	—
DVL-SLAM [59]	LiDAR + камера	0.98	—
PL-LOAM [60]	LiDAR + камера	0.94	0.36
KISS-ICP [36]	LiDAR	0.61	0.17
SOFT2 [61]	камера	0.71	0.24

Рассматриваемый метод представляет уникальный подход к объединению данных, исследование которого может способствовать развитию данного подхода. В связи с этим в качестве базового был выбран именно DVLO [50].

2.2. Принцип работы

2.2.1. Иерархическая экстракция признаков

Важную роль в представлении облаков точек, полученных с лидара $P_{\text{lidar}} = \{p_i \in \mathbb{R}^3 \mid i = 1, \dots, N\}$ играет переход к псевдоизображению. Для этого используется цилиндрическая проекция, которая задаётся формулами (2.1).

$$u = \frac{1}{\Delta\theta} \arctan 2(y, x), \quad v = \frac{1}{\Delta\varphi} \arcsin\left(\frac{z}{\sqrt{x^2 + y^2 + z^2}}\right), \quad (2.1)$$

где (x, y, z) — координаты точки в системе лидара, а $\Delta\theta$, $\Delta\varphi$ — шаг углов по горизонтали и вертикали соответственно. Таким образом, каждая точка проецируется в пиксель (u, v) . В соответствующую позицию записываются значения координат в результате чего формируется тензор (далее — псевдоизображение):

$$I_{\text{lidar}} \in \mathbb{R}^{H_P \times W_P \times 3}.$$

Для входного изображения $I_{\text{cam}} \in \mathbb{R}^{H \times W \times 3}$ применяется свёрточная сеть для выделения признаков в виде $F_I \in \mathbb{R}^{H_I \times W_I \times C_I}$, где H_I, W_I могут быть меньше исходных H, W , а C_I — количество каналов признаков. Аналогичным образом извлекаются признаки из псевдоизображений: $F_P \in \mathbb{R}^{H_P \times W_P \times C_P}$.

Описанные выше операции производятся несколько раз последовательно — в оригинальной архитектуре предусмотрено 4 уровня экстракции.

2.2.2. Локальное объединение признаков

Предложенный механизм локального объединения (англ. Local Fuser), позволяет объединять текстурные признаки изображения и геометрические признаки лидара в локальной окрестности. Основная идея состоит в представлении карты признаков изображения как множества псевдоточек аналогично методу, представленному в [приложении А](#), а каждый элемент облака точек при этом рассматривается в качестве центра контекстного кластера в дальнейшей обработке.

Пусть имеется карта признаков изображения $F_I \in \mathbb{R}^{H_I \times W_I \times C_I}$. Путём преобразования размерности формируется набор псевдоточек $F_{pp} \in \mathbb{R}^{M \times C_I}$, где $M = H_I \times W_I$ и каждая из них отвечает отдельной позиции в F_I .

Пусть лидарное облако P_{lidar} состоит из N 3D-точек. При известной калибровочной матрице можно спроецировать каждую $p_i \in P_{\text{lidar}}$ в плоскость изображения согласно уравнению (2.2).

$$(x'_i, y'_i) = \Pi_{\text{cam}}(p_i), \quad (2.2)$$

где Π_{cam} обозначает процедуру проекции в координаты изображения. Затем при помощи билинейной интерполяции извлекаются соответствующие признаки из F^I :

$$c_i = \text{Interp}(F_I, x'_i, y'_i) \in \mathbb{R}^{C_I}.$$

Каждый такой вектор c_i интерпретируется как центр кластера. Таким образом, общее число центров N совпадает с числом лидарных точек.

Пусть

$$\text{Sim}(i, j) = \frac{c_i^\top p_j}{\|c_i\| \|p_j\|} \in \mathbb{R}$$

обозначает косинусное сходство между i -м центром c_i и j -й псевдоточкой p_j из F_{pp} . Тогда для i -го кластера вычисляется агрегированный признак согласно формуле (2.3).

$$g_i = \frac{1}{1 + \sum_{j=1}^M \sigma(\alpha \text{Sim}(i, j) + \beta)} \left(c_i + \sum_{j=1}^M \sigma(\alpha \text{Sim}(i, j) + \beta) p_j \right), \quad (2.3)$$

где α, β — обучаемые скалярные параметры, а $\sigma(\cdot)$ — сигмоидальная функция.

Вектор $g_i \in \mathbb{R}^{C_I}$ становится локально-объединенным признаком для i -й лидарной точки. Итоговый тензор локальных признаков $F_L \in \mathbb{R}^{H_P \times W_P \times C_I}$ составлен из g_i на основе данных о соответствии проецированных точек.

2.2.3. Глобальное объединение признаков

После выполнения локального объединения, каждая лидарная точка обладает агрегированным признаком $g_i \in \mathbb{R}^{C_I}$, учитывающим локальную текстурную информацию из карты камеры. Однако локальное объединение охватывает лишь окрестности в признаковом пространстве, не обеспечивая достаточной глобальной взаимосвязи. Чтобы учесть более глобальный контекст и далее согласовать лидарные и визуальные особенности, используется выход

иерархического экстрактора признаков и осуществляется адаптивное объединение на уровне всей карты.

В итоге на вход поступает две карты признаков:

$$F_P \in \mathbb{R}^{H_P \times W_P \times C_P} \quad \text{и} \quad F_L \in \mathbb{R}^{H_P \times W_P \times C_L},$$

где F_P — признаки облака точек лидара, а F_L — результат локального объединения, учитывающий текстуры изображения. Для их глобального объединения вводится набор обучаемых весов, которые для каждой позиции (u, v) регулируют вклад F_P и F_L . В частности, можно ввести адаптивные карты A_P , A_L (одинакового размера), вычисляя их через небольшие полносвязные (MLP) или свёрточные слои:

$$A_P(u, v) = \sigma(\text{MLP}(F_P(u, v))), \quad A_L(u, v) = \sigma(\text{MLP}(F_L(u, v))),$$

где $\sigma(\cdot)$ — сигмоидальная функция, сжимающая выход в интервал $(0, 1)$. Тогда итоговый признак для позиции (u, v) :

$$F_G(u, v) = \frac{A_P(u, v) \odot F_P(u, v) + A_L(u, v) \odot F_L(u, v)}{A_P(u, v) + A_L(u, v) + \varepsilon}, \quad (2.4)$$

где символ $\odot$ обозначает покомпонентное умножение, а ε — малая константа для числовой стабильности.

Полученная карта $F_G \in \mathbb{R}^{H_P \times W_P \times d}$ содержит как исходную лидарную информацию, так и локально-агрегированные признаки, взвешенные согласно обучаемым коэффициентам в формуле (2.4), обеспечивая глобальный контекст и тем самым повышая устойчивость к шумам и неоднозначностям, связанным с локальными несоответствиями.

2.2.4. Итеративная оценка положения

После получения глобально объединенных признаков F_G^S , F_G^T для двух последовательных кадров (источника — « S » и цели — « T ») необходимо определить относительное перемещение между ними, то есть кватернион вращения $q \in \mathbb{R}^4$ и вектор смещения $t \in \mathbb{R}^3$.

Признаки F_G^S и F_G^T могут быть далее ассоциированы через механизм вычисления тензора соответствий (англ. cost embedding), отражающего, насколько

ко каждая позиция в кадре S соответствует аналогичной позиции в кадре T . Можем определить:

$$E = \text{CostEmbed}(F_G^S, F_G^T) \in \mathbb{R}^{H_p \times W_p \times d},$$

где $\text{CostEmbed}(\cdot, \cdot)$ — блок свёрточных слоёв и MLP, вычисляющий сходство между парами признаков. E представляется в виде массива $\mathbb{R}^{N \times d}$. В дальнейшем F_G приведены к такой же размерности.

Чтобы извлечь из E итоговые (q, t) , вводится небольшой регрессионный блок. Вычисляется карта $M \in \mathbb{R}^{H_p \times W_p \times d}$, которая содержит информацию о значимых областях, учитывая признаки E и F_G^S , после чего суммируется по пространственным координатам:

$$M = \text{softmax}\left(\text{MLP}(E \oplus F_G^S)\right), \quad m = \sum_{u,v} M(u, v) \odot E(u, v),$$

где $\oplus$ означает конкатенацию по каналной оси. В результате $m \in \mathbb{R}^d$ (после суммирования) служит входом для финального линейного слоя (2.5).

$$(\Delta q, \Delta t) = \text{FC}(m), \tag{2.5}$$

где $\Delta q \in \mathbb{R}^4$ и $\Delta t \in \mathbb{R}^3$ — предсказанные приращения, которые формируют текущую оценку (q, t) :

$$q_l = \Delta q_l \otimes q_{l+1}, \quad t_l = t_{l+1} + \text{Rot}(\Delta q_l) \Delta t_l, \tag{2.6}$$

где $\otimes$ обозначает умножение кватернионов, а $\text{Rot}(\Delta q)$ — матрица поворота, полученная из кватерниона Δq . Таким образом, на каждом уровне l уточняется грубая оценка (q_{l+1}, t_{l+1}) и в конце получаем итоговое (q_1, t_1) .

Чтобы модель могла извлечь грубые соответствия на низком разрешении и затем уточнить их с учётом более «детальных» признаков, процедура (2.6) повторяется на каждом уровне экстракции и объединения признаков. При этом формируется свой собственный cost embedding E_l и предсказываются $(\Delta q_l, \Delta t_l)$. Наконец, итоговая предсказанная поза (q_1, t_1) имеет существенно меньшую ошибку, чем грубая начальная (q_4, t_4) .

2.2.5. Функция потерь

Обучение сети происходит в парадигме обучения с учителем, опирающейся на эталонные относительные позы. Соответствующие эталонные значения обозначаются следующим образом q_{gt} и t_{gt} .

Для каждого из четырёх иерархических уровней вводится частичная функция потерь:

$$\mathcal{L}_l = \|t_{\text{gt}} - t_l\|_1 e^{-k_x} + k_x + \|q_{\text{gt}} - q_l\|_2 e^{-k_q} + k_q, \quad (2.7)$$

где $k_x, k_q \in \mathbb{R}$ — обучаемые скалярные параметры, служащие для автоматического подбора весов между трансляционной и вращательной составляющими ошибки. Кватернионы нормируются к единичной длине перед вычислением нормы.

Совокупная функция потерь формируется как взвешенная сумма частичных функций из уравнения (2.7):

$$\mathcal{L} = \sum_{l=1}^4 \alpha^l \mathcal{L}_l,$$

где коэффициенты α^l отражают вклад каждого уровня в итоговую оптимизацию.

Наличие экспоненциальных весов e^{-k_x} и e^{-k_q} обеспечивает адаптивное согласование масштабов двух слагаемых, что избавляет от ручного подбора статических коэффициентов. Обратные добавления k_x и k_q предотвращают неограниченный рост соответствующих параметров, сохраняя градиенты ненулевыми даже при малых ошибках.

2.3. Стереомодификация

В качестве одной из модификаций для улучшения качества работы модели предлагается интегрировать в архитектуру сети возможность использовать стерео-камеру: обрабатывать два изображения — левое и правое, каждое из которых соответствует собственному ракурсу. Дополнительная информация о сцене, получаемая за счёт стереопары может повысить робастность и точность итоговой одометрии, особенно при наличии частичных перекрытий или

динамических объектов.

В исходном подходе DVLO для этапа локального объединения каждая лидарная точка $p_i \in \mathbb{R}^3$ выступает центром кластера, проецируясь на одно изображение В предлагаемом расширении предполагается, что каждая лидарная точка проецируется на оба изображения. Далее эти признаки конкатенируются, для получения более полной локальной картины.

Пусть $F_{I_L} \in \mathbb{R}^{H_I \times W_I \times C_I}$ и $F_{I_R} \in \mathbb{R}^{H_I \times W_I \times C_I}$ — карты признаков для левого и правого изображений соответственно. Для локального объединения с камерой, как и прежде в формуле (2.2), формируются псевдоточки из каждого изображения: F_{ppL} и F_{ppR} . Затем каждая лидарная точка p_i проецируется как

$$(x'_i, y'_i)_L = \Pi_L(p_i), \quad (x'_i, y'_i)_R = \Pi_R(p_i),$$

где Π_L, Π_R — функции проекции с учётом калибровок соответствующих камер. Из F_{I_L} и F_{I_R} извлекаются центровые признаки $c_i^L, c_i^R \in \mathbb{R}^C$ (посредством билинейной интерполяции), которые играют роль кластерных центров для локального объединения.

Предлагается следующий вариант конкатенации:

$$c_i^{\text{concat}} = \text{Concat}(c_i^L, c_i^R) \in \mathbb{R}^{2C_I},$$

то есть центры из левого и правого изображения объединяются в один вектор. Аналогично псевдоточки конкатенируются в общий тензор:

$$F_{pp}^{\text{concat}} = F_{ppL} \cup F_{ppR},$$

и в процессе локального объединения на основе косинусного сходства все псевдоточки распределяются по классам в соответствии с близостью к c_i^{concat} . Таким образом, каждая лидарная точка получает обогащённый признак, который учитывает информацию стереопары.

Аналогично исходному методу, после получения локально объединенных признаков F_L происходит расчет глобальных признаков с помощью адаптивного механизма (2.4). Разница заключается лишь в том, что теперь F_L внутри уже содержит стерео-информацию.

3 Экспериментальная проверка

3.1. Набор данных

В качестве экспериментальной базы в настоящем исследовании используется публичный набор KITTI Odometry Benchmark [52], предназначенный для количественной оценки алгоритмов одометрии на данных лидара и стереокамеры.

3.1.1. Предоставляемые данные

Записи выполнены на мобильной платформе, оборудованной следующими датчиками:

- Лидар Velodyne HDL-64E: частота сканирования 10 Гц, 64 вертикальных луча, полный горизонтальный угол обзора 360° ,
- Стереосистема из двух камер PointGrey Flea: разрешение кадров 1241×376 , горизонтальный угол обзора $\approx 90^\circ$, частота съёмки 10 Гц, аппаратная синхронизация с лидаром,
- IMU/GPS, применяемые исключительно для построения опорной траектории; при проведении экспериментов не задействуются.

Кроме того, предоставляется калибровочная информация:

- $P_0 \in \mathbb{R}^{3 \times 4}$ — матрица проекции левой камеры,
- $P_1 \in \mathbb{R}^{3 \times 4}$ — матрица проекции правой камеры,
- $T_{velo \rightarrow l} \in \mathbb{R}^{4 \times 4}$ — матрица трансформации между системой координат лидара и левой камеры.

3.1.2. Структура и разбиение последовательностей

Всего датасет включает 22 последовательности (00–21). Эталонная траектория предоставлена только для последовательностей 00–10; оставшиеся 11–21 предназначены для внешнего тестирования на сервере.

В работе используется следующее разбиение:

- Обучающая выборка: последовательности 00–06,
- Тестовая выборка: последовательности 07–10.

3.1.3. Предобработка калибровочных данных

Для проведения проецирования лидарных точек на правое изображение необходимо получить матрицу трансформации между лидаром и правой камерой.

Зная матрицу проекции P_1 можно определить значения $R_{r \rightarrow l} \in \mathbb{R}^{3 \times 3}$ и $t_{r \rightarrow l} \in \mathbb{R}^{3 \times 1}$ — матрицы вращения и смещение между правой и левой камерами:

$$K_r, R_{r \rightarrow l} = RQ(M), \quad t_{r \rightarrow l} = R_{r \rightarrow l} M^{-1} P_{1|4},$$

где $P_1 = \begin{bmatrix} M & P_{1|4} \end{bmatrix}$, RQ — оператор RQ разложения. На основе полученных значений формируется матрица трансформации $T_{velo \rightarrow r}$:

$$T_{velo \rightarrow r} = T_{velo \rightarrow l} \begin{bmatrix} R_{r \rightarrow l} & t_{r \rightarrow l} \\ 0 & 1 \end{bmatrix}^{-1}$$

3.1.4. Метрики оценки

Для сопоставления с работами-аналогами используются стандартные метрики KITTI Odometry:

- средняя относительная трансляционная ошибка t_{rel} (RMSE, в процентах от пройденного пути),
- средняя относительная угловая ошибка r_{rel} (RMSE, в градусах на 100 м).

3.2. Методика экспериментов

Планируется проведение следующих экспериментов (на данных KITTI Odometry):

- обучение и тестирование стандартного метода DVLO,
- обучение и тестирование модифицированного метода DVLO со стереокамерой (далее Stereo-DVLO),

— запуск и тестирование одномодальных классических подходов.

Важно заметить, что эксперименты проводились при использовании монохромных изображений, предоставляемых набором данных, что может привести к отличию от заявленных результатов в таблице 2.1.

Эксперименты проводятся с использованием графического процессора NVIDIA RTX 3090. В качестве оптимизатора применяется Adam с параметрами $\beta_1 = 0.9$ и $\beta_2 = 0.999$. Начальный коэффициент скорости обучения устанавливается равным 0.001 и экспоненциально уменьшается каждые 200000 шагов до значения 0.00001. Размер mini-batch — 8. Коэффициенты α^l для четырёх уровней сети фиксируются как 1.6, 0.8, 0.4 и 0.2 соответственно. Начальные значения обучаемых параметров задаются следующим образом: $k_x = 0.0$, $k_q = -2.5$. Количество обучающих эпох — 300. Все указанные параметры выбраны в соответствии с рекомендациями в оригинальной статье.

3.3. Анализ результатов

На рисунке 3.1 изображен график сходимости функции потерь для методов DVLO и Stereo-DVLO: для обеих моделей значение функции потерь быстро падает в первые 20 эпох и далее плавно убывает; при этом кривая Stereo-DVLO расположена выше на всём интервале обучения, что может указывать на меньшую склонность к переобучению.

Численные итоги приведены в таблице 3.1. Стерео-модификация снижает среднюю относительную ошибку расстояния t_{rel} с 1.31% до 0.91% (улучшение на $\approx 30\%$) и среднюю относительную ошибку ориентации r_{rel} с $0.62^\circ/100$ м до $0.46^\circ/100$ м (улучшение на $\approx 26\%$). Улучшение наблюдается на большинстве последовательностей, что подтверждает устойчивый вклад дополнительной камеры.

Сравнения траекторий, показанные на рисунках 3.2-3.5, иллюстрируют, что Stereo-DVLO точнее воспроизводит форму маршрута и аккумулирует заметно меньший дрейф, особенно на длинных прямолинейных участках и резких разворотах, где базовый DVLO склонен к накоплению ошибок.

Среднее время обработки последовательных кадров составляет 0.098 с при использовании 6 Гб видео-памяти, что позволяет обрабатывать данные в режиме реального времени.




Рисунок 3.1 — Зависимость значения функции потерь от количества обучающих эпох для методов DVLO и Stereo-DVLO

Таблица 3.1 — Сравнение относительных ошибок одометрии на последовательностях 00–10 (KITTI Odometry)

Послед.	DVLO		Stereo-DVLO	
	$t_{rel}, \%$	$r_{rel}, ^\circ/100 \text{ м}$	$t_{rel}, \%$	$r_{rel}, ^\circ/100 \text{ м}$
00	1.08	0.50	0.99	0.47
01	1.25	0.47	1.10	0.36
02	1.55	0.54	1.01	0.35
03	0.96	0.46	1.01	0.81
04	0.67	0.63	0.61	0.36
05	1.34	0.62	0.68	0.34
06	1.00	0.49	0.37	0.19
07	1.10	0.69	0.81	0.47
08	1.73	0.67	1.32	0.63
09	1.35	0.56	1.06	0.48
10	2.31	1.24	1.09	0.57
Среднее	1.31	0.62	0.91	0.46




Рисунок 3.2 — Сравнение предсказанной траектории 07 с эталонной для методов DVLO и Stereo-DVLO




Рисунок 3.3 — Сравнение предсказанной траектории 08 с эталонной для методов DVLO и Stereo-DVLO




Рисунок 3.4 — Сравнение предсказанной траектории 09 с эталонной для методов DVLO и Stereo-DVLO




Рисунок 3.5 — Сравнение предсказанной траектории 10 с эталонной для методов DVLO и Stereo-DVLO

В совокупности, результаты свидетельствуют о значимом повышении качества работы при использовании дополнительной камеры без заметного влияния на устойчивость и скорость сходимости обучения.

Также было проведено сравнение с современными методами KISS-ICP и SOFT2 на тестовых последовательностях 07-10 (показатели SOFT2 рассчитаны при запуске с использованием монохромных изображений). Результаты представлены в таблице 3.2.

Таблица 3.2 — Сравнение одометрических ошибок на последовательностях 07–10.

Послед.	Stereo-DVLO		KISS-ICP		SOFT2	
	$t_{\text{rel}}, \%$	$r_{\text{rel}}, ^\circ / 100\text{м}$	$t_{\text{rel}}, \%$	$r_{\text{rel}}, ^\circ / 100\text{м}$	$t_{\text{rel}}, \%$	$r_{\text{rel}}, ^\circ / 100\text{м}$
07	0.81	0.47	0.38	0.16	0.44	0.18
08	1.32	0.63	0.82	0.19	0.91	0.21
09	1.06	0.48	0.53	0.14	0.60	0.15
10	1.09	0.57	0.51	0.19	0.55	0.20
Среднее	1.07	0.53	0.56	0.17	0.62	0.19

Как видно, KISS-ICP и SOFT2, являясь классическими оптимизационными методами, демонстрируют более низкие ошибки t_{rel} и r_{rel} , однако требуют тщательной калибровки и подбора параметров для обеспечения высокой точности на конкретном наборе данных. При этом предложенная Stereo-DVLO остаётся полностью дифференцируемой, легко расширяется под использование новых сенсоров, может быть обучена на разнообразном наборе данных, что способствует робастности в ряде реальных сценариев.

4 Методические рекомендации

4.1. Рекомендации по использованию

На основе опыта, полученного при проведении экспериментов с методом DVLO и предложенной модификацией можно выделить следующие рекомендации по использованию:

- В качестве оборудования для получения данных стоит выбирать камеры и лидар высокого разрешения для обеспечения возможности экстракции большего количества признаков и учета их при регрессии положения системы в ходе работы алгоритма.
- Ключевую роль в работоспособности метода играет синхронизация данных. Наличие смещения по времени между показаниями датчиков может повлечь искажение проекции лидарных точек в систему координат камеры, что усложнит процесс обучения и приведет к снижению качества одометрии.
- На качество проекции при экстракции признаков и локальном объединении влияет также взаимная калибровка камеры и лидара. В связи с этим рекомендуется тщательно верифицировать параметры системы сенсоров.
- На начальном этапе обучения важно обеспечить равный вклад трансляционной ошибки и ошибки ориентации в функцию потерь, для этого значения адаптивных коэффициентов k_x и k_q выбираются исходя из условия совпадения масштаба данных значений. Для различных данных может потребоваться пересмотр предлагаемых в оригинальной статье начальных условий.

4.2. Потенциальные улучшения

Ниже представлены наиболее перспективные расширения, которые могут существенным образом повысить точность и робастность одометрии. Кроме

того стоит отметить, что использование полностью дифференцируемого алгоритма позволяет значительно расширять ее функционал путем добавления параллельных блоков, использующих признаки из основной модели.

4.2.1. Учёт временного контекста посредством трансформера

В текущей реализации DVLO / Stereo-DVLO каждая пара последовательных кадров обрабатывается независимо. Это не позволяет модели использовать дополнительную динамическую информацию, что могло бы позволить обрабатывать более сложные профили движения. Возможным решением является использование временного трансформера (англ. Temporal Transformer), принимающего в окно несколько последних глобально объединенных признаков F_G . Механизм внимания может обеспечить адаптивный учет вкладов прошлых кадров, выделяя длительные закономерности в данных и подавляя шум.

4.2.2. Использование оценки глубины

Помимо прямой интеграции второй камеры в оригинальную структуру DVLO для учета текстурной информации, предлагается первично оценивать глубину при помощи компактной нейронной сети (например H-Net [62]). Далее при локальном объединении помимо цветовых признаков каждой точки используется также признак глубины. Такая схема позволяет сохранить парадигму полностью нейросетевого подхода одометрии, при этом также позволяет расширить его применимость за счет повышения точности и функциональности (оценки глубины можно использовать независимо для параллельных задач).

ЗАКЛЮЧЕНИЕ

В результате выполнения выпускной квалификационной работы был проведен анализ существующих методов визуальной и лидарной одометрии, а также мультимодальных подходов. Выделены основные классы широко используемых методов. В качестве основы для разработки был выбран полностью нейросетевой метод DVLO.

Идея метода DVLO состоит в особой процедуре экстракции, а также объединения локальных и глобальных признаков облаков точек и изображений. В частности, используется подход кластеризации признаков, предложенный в работе Image as Set of Points (приложение А).

Используя открытый набор данных KITTI Odometry [52] были проведены эксперименты с базовой версией метода, а также с предложенной модификацией, использующей вторую камеру для уточнения предсказаний. После обучения и валидации удалось показать значительное уменьшение средних значений ошибок положения и ориентации (на 30% и 26% соответственно).

Средняя частота обработки потока данных разработанного метода составляет 10.2 Гц при использовании до 6 Гб видеопамати. Относительные ошибки оценки расстояния и ориентации находятся на уровне 0.91% и 0.46°/100м соответственно. Полученные характеристики удовлетворяют требованиям, установленным в техническом задании — частота работы не менее 8 Гц, количество доступной видеопамати не менее 8 Гб, относительные ошибки расстояния и ориентации менее 2% и 0.6°/100м.

Для проведения сравнительного анализа также были поставлены эксперименты с классическими методами визуальной и лидарной одометрии. Результаты свидетельствуют о превосходстве современных классических методов, основанных на оптимизации над полностью нейросетевыми. Однако, последние обладают потенциалом к существенному расширению области применения за счет возможности дообучения параллельных слоев для решения других задач. Кроме того, классические методы часто требуют тщательной настройки параметров перед использованием в конкретном окружении в отличие от нейросетевых моделей.

В данной работе продемонстрирована возможность масштабирования нейросетевых методов на новые сенсоры, что указывает на перспективность подобных разработок в будущем.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Nistér D., Naroditsky O., Bergen J. Visual odometry // Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2004. CVPR 2004. / Ieee. Vol. 1. 2004. P. I–I.
2. Review of visual odometry: types, approaches, challenges, and applications / Mohammad OA Aqel, Mohammad H Marhaban, M Iqbal Saripan, Nap̄siah Bt Ismail // SpringerPlus. 2016. Vol. 5. P. 1–26.
3. A review of monocular visual odometry / Ming He, Chaozheng Zhu, Qian Huang et al. // The Visual Computer. 2020. Vol. 36. No. 5. P. 1053–1065.
4. Zhang Z. Determining the epipolar geometry and its uncertainty: A review // International journal of computer vision. 1998. Vol. 27. P. 161–195.
5. Hartley R. I. In defense of the eight-point algorithm // IEEE Transactions on pattern analysis and machine intelligence. 1997. Vol. 19. No. 6. P. 580–593.
6. Nistér D. An efficient solution to the five-point relative pose problem // IEEE transactions on pattern analysis and machine intelligence. 2004. Vol. 26. No. 6. P. 756–770.
7. Fischler M. A., Bolles R. C. Random sample consensus: a paradigm for model fitting with applications to image analysis and automated cartography // Communications of the ACM. 1981. Vol. 24. No. 6. P. 381–395.
8. Thurmond V. A. The point of triangulation // Journal of nursing scholarship. 2001. Vol. 33. No. 3. P. 253–258.
9. Li S., Xu C., Xie M. A robust o (n) solution to the perspective-n-point problem // IEEE transactions on pattern analysis and machine intelligence. 2012. Vol. 34. No. 7. P. 1444–1450.
10. Lepetit V., Moreno-Noguer F., Fua P. Ep n p: An accurate o (n) solution to the p n p problem // International journal of computer vision. 2009. Vol. 81. P. 155–166.
11. Kneip L., Li H., Seo Y. Upnp: An optimal o (n) solution to the absolute pose problem with universal applicability // Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6–12, 2014, Proceedings, Part I 13 / Springer. 2014. P. 127–142.
12. Revisiting the pnp problem: A fast, general and optimal solution / Yin̄qiang Zheng, Yubin Kuang, Shigeki Sugimoto et al. // Proceedings of the

- IEEE International Conference on Computer Vision. 2013. P. 2344–2351.
13. Bundle adjustment—a modern synthesis / Bill Triggs, Philip F McLauchlan, Richard I Hartley, Andrew W Fitzgibbon // *Vision Algorithms: Theory and Practice: International Workshop on Vision Algorithms Corfu, Greece, September 21–22, 1999 Proceedings* / Springer. 2000. P. 298–372.
 14. Mur-Artal R., Montiel J. M. M., Tardos J. D. Orb-slam: A versatile and accurate monocular slam system // *IEEE transactions on robotics*. 2015. Vol. 31. No. 5. P. 1147–1163.
 15. Mur-Artal R., Tardós J. D. Orb-slam2: An open-source slam system for monocular, stereo, and rgb-d cameras // *IEEE transactions on robotics*. 2017. Vol. 33. No. 5. P. 1255–1262.
 16. Orb-slam3: An accurate open-source library for visual, visual–inertial, and multimap slam / Carlos Campos, Richard Elvira, Juan J Gómez Rodríguez et al. // *IEEE transactions on robotics*. 2021. Vol. 37. No. 6. P. 1874–1890.
 17. Orb: An efficient alternative to sift or surf / Ethan Rublee, Vincent Rabaud, Kurt Konolige, Gary Bradski // *2011 International conference on computer vision* / Ieee. 2011. P. 2564–2571.
 18. Qader W. A., Ameen M. M., Ahmed B. I. An overview of bag of words; importance, implementation, applications, and challenges // *2019 international engineering conference (IEC)* / IEEE. 2019. P. 200–204.
 19. g 2 o: A general framework for graph optimization / Rainer Kümmerle, Giorgio Grisetti, Hauke Strasdat et al. // *2011 IEEE international conference on robotics and automation* / IEEE. 2011. P. 3607–3613.
 20. Structure plp-slam: Efficient sparse mapping and localization using point, line and plane for monocular, rgb-d and stereo cameras / Fangwen Shu, Jiaxuan Wang, Alain Pagani, Didier Stricker // *2023 IEEE International Conference on Robotics and Automation (ICRA)* / IEEE. 2023. P. 2105–2112.
 21. Lsd: A line segment detector / Rafael Grompone Von Gioi, J  r  mie Jakubowicz, Jean-Michel Morel, Gregory Randall // *Image Processing On Line*. 2012. Vol. 2. P. 35–55.
 22. Zhang L., Koch R. An efficient and robust line segment matching approach based on lbd descriptor and pairwise geometric consistency // *Journal of visual communication and image representation*. 2013. Vol. 24. No. 7. P. 794–805.
 23. Engel J., Koltun V., Cremers D. Direct sparse odometry // *IEEE transac  *

- tions on pattern analysis and machine intelligence. 2017. Vol. 40. No. 3. P. 611–625.
24. DeTone D., Malisiewicz T., Rabinovich A. Superpoint: Self-supervised interest point detection and description // Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2018. P. 224–236.
 25. Teed Z., Deng J. Droid-slam: Deep visual slam for monocular, stereo, and rgb-d cameras // Advances in neural information processing systems. 2021. Vol. 34. P. 16558–16569.
 26. Rao S. Supervo: A monocular visual odometry based on learned feature matching with gnn // 2021 IEEE International Conference on Consumer Electronics and Computer Engineering (ICCECE) / IEEE. 2021. P. 18–26.
 27. Dyna-vo: A semantic visual odometry in dynamic environment / Tianli Ma, Jie Zhang, Song Gao, Chaobo Chen // 2021 China Automation Congress (CAC) / IEEE. 2021. P. 477–482.
 28. Magicvo: An end-to-end hybrid cnn and bi-lstm method for monocular visual odometry / Jichao Jiao, Jian Jiao, Yaokai Mo et al. // IEEE Access. 2019. Vol. 7. P. 94118–94127.
 29. Lidar odometry survey: recent advancements and remaining challenges / Dongjae Lee, Minwoo Jung, Wooseong Yang, Ayoung Kim // Intelligent Service Robotics. 2024. Vol. 17. No. 2. P. 95–118.
 30. Arun K. S., Huang T. S., Blostein S. D. Least-squares fitting of two 3-d point sets // [IEEE Transactions on Pattern Analysis and Machine Intelligence](#). 1987. Vol. PAMI-9. No. 5. P. 698–700.
 31. He L., Jin Z., Gao Z. De-skewing lidar scan for refinement of local mapping // Sensors. 2020. Vol. 20. No. 7. P. 1846.
 32. Low K.-L. Linear least-squares optimization for point-to-plane icp surface registration // Chapel Hill, University of North Carolina. 2004. Vol. 4. No. 10. P. 1–3.
 33. Segal A., Haehnel D., Thrun S. Generalized-icp. // Robotics: science and systems / Seattle, WA. Vol. 2. 2009. P. 435.
 34. Ndt-transformer: Large-scale 3d point cloud localisation using the normal distribution transform representation / Zhicheng Zhou, Cheng Zhao, Daniel Adolfsson et al. // 2021 IEEE international conference on robotics and automation (ICRA) / IEEE. 2021. P. 5654–5660.

35. Ct-icp: Real-time elastic lidar odometry with loop closure / Pierre Dellenbach, Jean-Emmanuel Deschaud, Bastien Jacquet, François Goulette // 2022 International Conference on Robotics and Automation (ICRA) / IEEE. 2022. P. 5580–5586.
36. Kiss-icp: In defense of point-to-point icp—simple, accurate, and robust registration if done the right way / Ignacio Vizzo, Tiziano Guadagnino, Benedikt Mersch et al. // IEEE Robotics and Automation Letters. 2023. Vol. 8. No. 2. P. 1029–1036.
37. Zhang J., Singh S. et al. Loam: Lidar odometry and mapping in real-time. // Robotics: Science and systems / Berkeley, CA. Vol. 2. 2014. P. 1–9.
38. Shan T., Englot B. Lego-loam: Lightweight and ground-optimized lidar odometry and mapping on variable terrain // 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS) / IEEE. 2018. P. 4758–4765.
39. Behley J., Stachniss C. Efficient surfel-based slam using 3d laser range data in urban environments. // Robotics: science and systems. Vol. 2018. 2018. P. 59.
40. Suma++: Efficient lidar-based semantic slam / Xieyuanli Chen, Andres Milioto, Emanuele Palazzolo et al. // 2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS) / IEEE. 2019. P. 4530–4537.
41. Rangenet++: Fast and accurate lidar semantic segmentation / Andres Milioto, Ignacio Vizzo, Jens Behley, Cyrill Stachniss // 2019 IEEE/RSJ international conference on intelligent robots and systems (IROS) / IEEE. 2019. P. 4213–4220.
42. Glim: 3d range-inertial localization and mapping with gpu-accelerated scan matching factors / Kenji Koide, Masashi Yokozuka, Shuji Oishi, Atsuhiko Banno // Robotics and Autonomous Systems. 2024. Vol. 179. P. 104750.
43. Blanco-Claraco J. L. A flexible framework for accurate lidar odometry, map manipulation, and localization // The International Journal of Robotics Research. 2024. P. 02783649251316881.
44. Lo-net: Deep real-time lidar odometry / Qing Li, Shaoyang Chen, Cheng Wang et al. // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019. P. 8473–8482.
45. Lodonet: A deep neural network with 2d keypoint matching for 3d lidar

- odometry estimation / Ce Zheng, Yecheng Lyu, Ming Li, Ziming Zhang // Proceedings of the 28th ACM international conference on multimedia. 2020. P. 2391–2399.
46. Pointnet: Deep learning on point sets for 3d classification and segmentation / Charles R Qi, Hao Su, Kaichun Mo, Leonidas J Guibas // Proceedings of the IEEE conference on computer vision and pattern recognition. 2017. P. 652–660.
 47. Cho Y., Kim G., Kim A. Unsupervised geometry-aware deep lidar odometry // 2020 IEEE international conference on robotics and automation (ICRA) / IEEE. 2020. P. 2145–2152.
 48. Zhang J., Singh S. Visual-lidar odometry and mapping: Low-drift, robust, and fast // 2015 IEEE international conference on robotics and automation (ICRA) / IEEE. 2015. P. 2174–2181.
 49. Graeter J., Wilczynski A., Lauer M. Limo: Lidar-monocular visual odometry // 2018 IEEE/RSJ international conference on intelligent robots and systems (IROS) / IEEE. 2018. P. 7872–7879.
 50. Dvlo: Deep visual-lidar odometry with local-to-global feature fusion and bidirectional structure alignment / Jiuming Liu, Dong Zhuo, Zhiheng Feng et al. // European Conference on Computer Vision / Springer. 2024. P. 475–493.
 51. 4drvo-net: Deep 4d radar–visual odometry using multi-modal and multi-scale adaptive fusion / Guirong Zhuo, Shouyi Lu, Huanyu Zhou et al. // IEEE Transactions on Intelligent Vehicles. 2023. Vol. 9. No. 6. P. 5065–5079.
 52. Vision meets robotics: The kitti dataset / Andreas Geiger, Philip Lenz, Christoph Stiller, Raquel Urtasun // The international journal of robotics research. 2013. Vol. 32. No. 11. P. 1231–1237.
 53. Aydemir E., Fetic N., Unel M. H-vlo: hybrid lidar-camera fusion for self-supervised odometry // 2022 IEEE/RSJ international conference on intelligent robots and systems (IROS) / IEEE. 2022. P. 3302–3307.
 54. Efficient 3d deep lidar odometry / Guangming Wang, Xinrui Wu, Shuyang Jiang et al. // IEEE Transactions on Pattern Analysis and Machine Intelligence. 2022. Vol. 45. No. 5. P. 5749–5765.
 55. Translo: A window-based masked point transformer framework for large-scale lidar odometry / Jiuming Liu, Guangming Wang, Chaokang Jiang et al. // Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 37. 2023.

- P. 1683–1691.
56. D3vo: Deep depth, deep pose and deep uncertainty for monocular visual odometry / Nan Yang, Lukas von Stumberg, Rui Wang, Daniel Cremers // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020. P. 1281–1292.
 57. Deep virtual stereo odometry: Leveraging deep depth prediction for monocular direct sparse odometry / Nan Yang, Rui Wang, Jorg Stuckler, Daniel Cremers // Proceedings of the European conference on computer vision (ECCV). 2018. P. 817–833.
 58. Zhang J., Singh S. Visual-lidar odometry and mapping: low-drift, robust, and fast // 2015 IEEE International Conference on Robotics and Automation (ICRA). 2015. P. 2174–2181.
 59. Shin Y.-S., Park Y. S., Kim A. Dvl-slam: Sparse depth enhanced direct visual-lidar slam // Autonomous Robots. 2020. Vol. 44. No. 2. P. 115–130.
 60. Lidar-monocular visual odometry using point and line features / Shi-Sheng Huang, Ze-Yu Ma, Tai-Jiang Mu et al. // 2020 IEEE International Conference on Robotics and Automation (ICRA). 2020. P. 1091–1097.
 61. Cvišić I., Marković I., Petrović I. Soft2: Stereo visual odometry for road vehicles based on a point-to-epipolar-line metric // IEEE Transactions on Robotics. 2022. Vol. 39. No. 1. P. 273–288.
 62. H-net: Unsupervised attention-based stereo depth estimation leveraging epipolar geometry / Baoru Huang, Jian-Qing Zheng, Stamatia Giannarou, Daniel S Elson // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022. P. 4460–4467.
 63. Image as set of points / Xu Ma, Yuqian Zhou, Huan Wang et al. // arXiv preprint arXiv:2303.01494. 2023.
 64. Simonyan K., Zisserman A. Very deep convolutional networks for large-scale image recognition // arXiv preprint arXiv:1409.1556. 2014.
 65. An image is worth 16x16 words: Transformers for image recognition at scale / Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov et al. // arXiv preprint arXiv:2010.11929. 2020.

ПРИЛОЖЕНИЕ А ИЗОБРАЖЕНИЕ КАК НАБОР ТОЧЕК

Важную роль в рассматриваемом в работе методе играет особый способ представления изображений как набора точек на основе контекстной кластеризации [63]. Идея заключается в использовании нового подхода для экстракции признаков при работе с визуальными данными, позволяющем увеличить эффективность при качестве сравнимом с широко применяемыми сверточными нейронными сетями [64] и визуальными трансформерами [65].

Конвенционально изображения представлялись в качестве прямоугольного $h \times w$ трехканального массива $I \in \mathbb{R}^{h \times w \times 3}$. В данном подходе предлагается использовать пространственную информацию о положении пикселя в качестве непосредственно первичного признака, а все изображение рассматривать как неупорядоченный набор точек с обобщенными признаками $I^P \in \mathbb{R}^{n_p \times 5}$, где $n_p = h \cdot w$. При этом пространственная информация каждого пикселя $I_{i,j}$ представляется следующим образом: $\left[\frac{i}{h} - 0.5 \quad \frac{j}{w} - 0.5 \right]$.

После преобразования изображений производится иерархическая экстракция признаков. Первым шагом является редуцирование набора точек посредством равномерного выбора ключевых точек и проецирования некоторой окрестности при помощи линейного слоя в единое представление. После редуцирования применяется процедура контекстной кластеризации, что и является ключевой идеей предлагаемого метода. Редуцированные точки проецируются в пространство сравнения при помощи полносвязной нейронной сети. Среди полученных точек $I_s^p \in \mathbb{R}^{n_r \times d}$ (количество признаков может меняться при проецировании) также равномерно выбираются центры будущих c кластеров — их признаки рассчитываются как среднее среди k ближайших соседей. Затем рассчитывается карта сходства $S \in \mathbb{R}^{c \times n_r}$ на основе косинусного расстояния между центрами кластеров и точками. Таким образом, используя карту сходства можем определить принадлежность точек к кластерам. Имея кластер, состоящий из m точек и соответствующие им значения сходства $s \in \mathbb{R}^m$ производится проецирование в пространство значений $I_v^p \in \mathbb{R}^{n_r \times d'}$ (также проецируется центр кластера v_c). Рассчитывается агрегированный признак класса:

$$g = \frac{1}{C} \left(v_c + \sum_{i=1}^m \sigma(\alpha s_i + \beta) \cdot v_i \right), \quad C = 1 + \sum_{i=1}^m \sigma(\alpha s_i + \beta),$$

где v_i — значение для i -й точки кластера, σ — сигмоидальная функция, α и β

— обучаемые параметры. После получения g предлагается обновить признаки каждой точки кластера. Пусть $p_i \in \mathbb{R}^d$ — исходный вектор признаков i -й точки. Итоговое обновление выполняется формулой (6.1).

$$p'_i = p_i + \text{FC}\left(\sigma(\alpha s_i + \beta) \cdot g\right), \quad (6.1)$$

где FC — полносвязный слой, отображающий из $\mathbb{R}^{d'}$ в $\mathbb{R}^d$. Таким образом, каждая точка получает «распространённый» признак, пропорциональный величине сходства s_i . Данная процедура повторяется несколько раз в зависимости от количества блоков в иерархическом модуле.